

Control de Diversidad aplicado a Algoritmos Genéticos en la Solución de Problemas de Optimización Multimodal

Edwin Sneyder Gantiva Ramos¹

Universidad Nacional de Colombia, Bogotá, Colombia,
I.esgantivar@unal.edu.co

Abstract. Este documento tiene como objetivo estudiar el control de diversidad sobre la población de individuos que hacen parte de una generación dentro de un proceso evolutivo, esto se aborda con la estrategia de niching, que nuevamente está inspirada en los comportamientos de la evolución natural. En cuanto a implementación se ha usado el Deterministic Crowding, incluyendo políticas de restricción de cruce (Recombinación)[4]. Nuevamente cada individuo tiene codificado en su cromosoma las ratas asociadas a las tasas de aprendizaje de los operadores, que fue desarrollado anteriormente y presentado en [2]. Estas nuevas implementaciones han presentado excelentes resultados para la solución de problemas multimodales.

Keywords: Optimización, Algoritmos Genéticos, Control de Diversidad, Deterministic Crowding

1 Introducción

Muy a menudo, encontramos problemas de optimización que logramos solucionar haciendo uso de algoritmos genéticos, esto junto con estrategias evolutivas es hoy en día una técnica muy poderosa en términos de solucionar problemas de con altos niveles de dimensión, sin embargo el comportamiento por el que se caracteriza la población de un algoritmo genético es la convergencia a un único individuo puesto que los parámetros para escoger a los parientes candidatos esta únicamente basado en su comportamiento con respecto al fitness. Esto constituye un problema puesto que muchos de los problemas tienen una naturaleza multimodal y en algunos casos estamos más interesados en conocer múltiples óptimos locales y no un único óptimo que usualmente se considera como óptimo global.

Así como los algoritmos genéticos están inspirados en los comportamientos y patrones de la naturaleza, así mismo emerge una solución para la problemática que se ha mencionado. En la naturaleza la evolución de las especies se ha restringido por características naturales como los accidentes geográficos, la geografía, los océanos, etc. Con esto la naturaleza ha logrado mantener diversidad en sus especies promoviendo y protegiendo la evolución especializada

II

y aislada, eso lo conocemos como niches de especies. Esta idea es la base del método de Deterministic Crowding que surge como una solución al problema de niching en algoritmos genéticos. Aunque no es la única alternativa existente para dar solución a este problema, estudios presentados anteriormente como en [1] demuestran que Deterministic Crowding resulta ser una técnica con buenos resultados.

Este documento se desarrollara de la siguiente manera: Se tendrá una sección de marco teórico donde se expondrán las principales ideas de las diferentes técnicas que se han propuesto para darle solución a este problema, seguido de esto se hará una descripción de las propuestas que se hacen para la solución de este problema y para terminar se muestran los resultados de aplicar e implementar esta propuesta usando funciones frecuentemente usadas presentadas en [3].

2 Marco Teórico

Algoritmo Genético Convencional:

El algoritmo genético convencional es el concepto base para el desarrollo de este documento, este en términos sencillos busca dada una función de fitness y un conjunto de población inicial busca evolucionar el rendimiento del conjunto de los individuos sobre la función de fitness generación tras generación.

Algorithm 2.1: Algoritmo Genetico($f, \mu, CondicionDeTerminacion$)

```
1 Inicializar la Población Inicial  $P_0$ ;  
2 Evaluar( $P_0, f$ );  
3 while  $CondiciondeTerminacion$  do  
4    $descendientes = GENERACION(P_t, f, SELECCION)$ ;  
5    $P_t = FUNCION\_REEMPLAZO(descendientes, P_{t-1})$ 
```

Para el desarrollo de este documento se han aplicado operadores genéticos auto adaptativos que fueron desarrollados en documentos anteriores y cuya idea fue introducida en [2].

2.1 El Problema de Diversidad

En los algoritmos genéticos que no aplican estrategias para el control de la diversidad se presenta un problema que es comúnmente conocido como el problema de la recombinación, que se da dado que en estos algoritmos cualquier individuo puede "procrear" con cualquier otro sin ningún tipo de restricción.

En busca de dar solución nació una técnica conocida como la estrategia de "Sharing" cuya dinámica se puede resumir en el valor alcanzado por el fitness en

un punto del espacio donde se encuentra un optimo local es repartido entre todos los individuos que entren a este optimo local, sin embargo con eso se genera una dinámica de entrar y salir de forma secuencial de los óptimos locales.

Por otro lado tenemos la estrategia de Deterministic Crowding que se basa en una función de distancia o similaridad, puesto que un individuo solo puede procrearse con el otro individuo de la población que se encuentra mas cerca o sea mas similar, según sea el caso. Hay que hacer la claridad que esto tendrá una complejidad computacional de orden cuadrado puesto que cada individuo debe tener calculada su medida de distancia o similaridad a cada uno de los demás individuos de la población.

3 Propuesta

Teniendo lo anterior, para el desarrollo de este documento se ha tomado la decisión de tomar la estrategia de Deterministic Crowding, que puede ser aplicada de una manera casi transparente a trabajos anteriormente realizados.

Sin embargo aun tenemos el problema de la complejidad computacional que genera el aplicar esta estrategia, por lo cual se decide aplicar un concepto que es presentado en [3] que se conoce como "Meeting Factor" que hace que la complejidad se reduzca a una complejidad lineal, pero que este **MF**, su concepto es sencillo, se eligen de manera aleatoria un conjunto de individuos de tamaño **MF** y sobre este se aplican las funciones para obtener las medidas de distancia. Posterior a esto se aplica el Deterministic Crowding.

La implementación es sencilla en el algoritmo desarrollado para trabajos anteriores, que se encuentra disponible en Repositorio en GitHub, en este algoritmo cada generación un único operador genético es aplicado a cada individuo y el descendiente puede tomar el lugar de su pariente en la siguiente población si su fitness es mayor o al menos igual que el de su pariente.

De acuerdo con los operadores genéticos propuestos, estos pueden ser clasificados en los operadores de ariedad uno y ariedad dos, en caso de aplicar un operador de ariedad 2 el algoritmo escoge un individuo de la población de candidatos de acuerdo a una estrategia de selección. En este momento es cuando aplicamos la estrategia de Deterministic Crowding.

La política para escoger a los parientes adicionales que necesite el operador genético estará restringida unicamente a la distancia y no a su función de fitness. Garantizando con esto una aproximación a la solución del problema de la recombinación. En la siguiente sección se presentan los resultado obtenidos después de aplicar esta estrategia.

4 Resultados

Para el estudio de los resultados de la propuesta se ha hecho sobre unas funciones que son conocidas en el problema de optimización multimodal, estas son M_1 , M_2 , M_3 y M_4 que son presentadas en [3]. Los resultados se presentan en (Fig. 1- Fig. 12). Mostrando como a través de las generaciones los algoritmos se van aglomerando alrededor de un optimo local, o como lo hemos llamado anteriormente un niche.

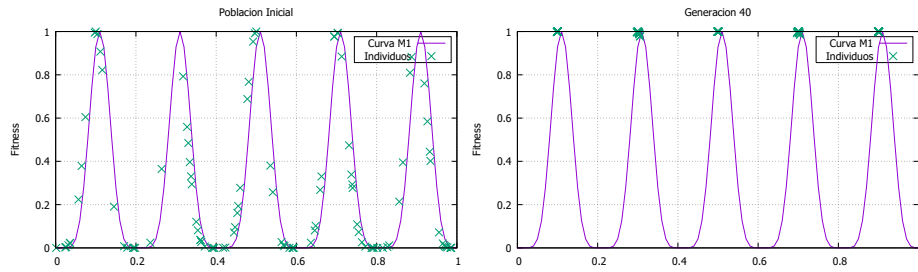


Fig. 1. Del lado izquierdo la distribución de la población Inicial, Del lado derecho la distribución de la población en la Generación 40




Fig. 2. Del lado izquierdo la distribución de la población en la generación 80, Del lado derecho la distribución de la población en la Generación 120

5 Conclusiones

1. Aplicando el concepto de **MF** se ha logrado reducir la complejidad computacional del algoritmo genetico.




Fig. 3. Del lado izquierdo la distribución de la población en la generación 160, Del lado derecho la distribución de la población en la Generación 200

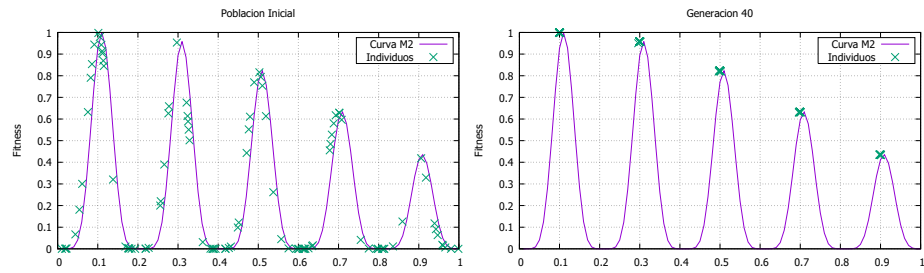


Fig. 4. Del lado izquierdo la distribución de la población Inicial, Del lado derecho la distribución de la población en la Generación 40

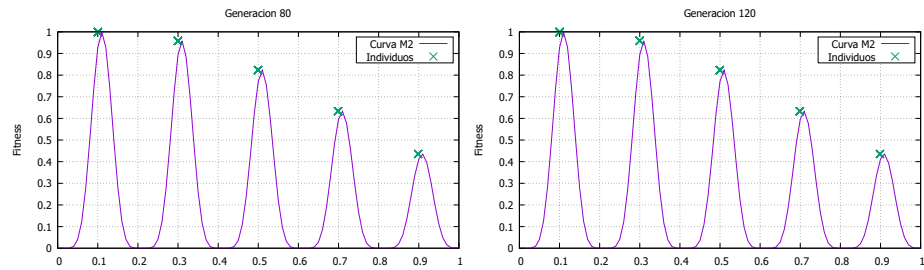


Fig. 5. Del lado izquierdo la distribución de la población en la generación 80, Del lado derecho la distribución de la población en la Generación 120

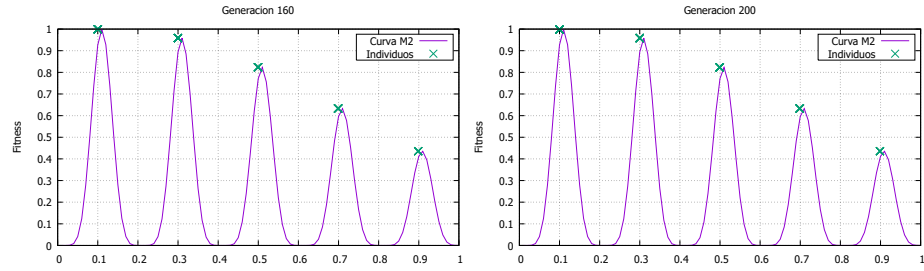


Fig. 6. Del lado izquierdo la distribución de la población en la generación 160, Del lado derecho la distribución de la población en la Generación 200

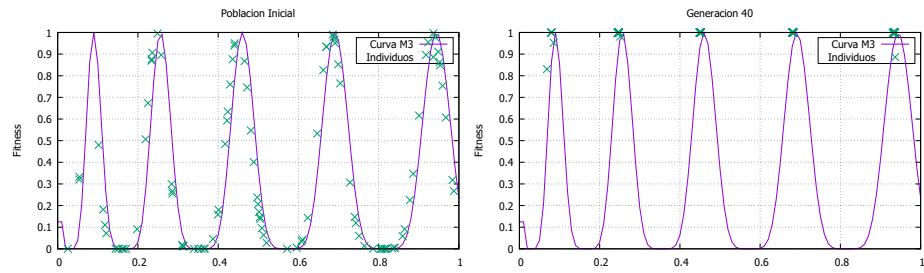


Fig. 7. Del lado izquierdo la distribución de la población Inicial, Del lado derecho la distribución de la población en la Generación 40




Fig. 8. Del lado izquierdo la distribución de la población en la generación 80, Del lado derecho la distribución de la población en la Generación 120




Fig. 9. Del lado izquierdo la distribución de la población en la generación 160, Del lado derecho la distribución de la población en la Generación 200

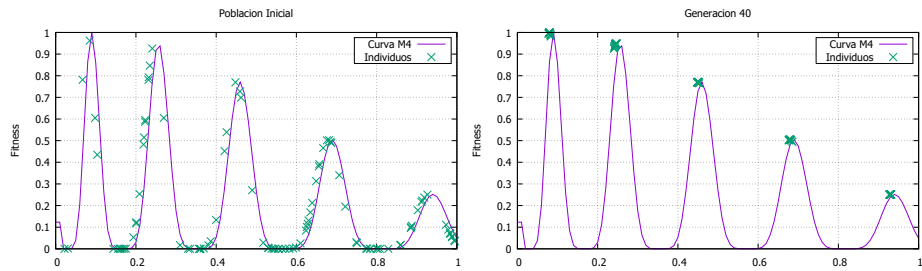


Fig. 10. Del lado izquierdo la distribución de la población Inicial, Del lado derecho la distribución de la población en la Generación 40




Fig. 11. Del lado izquierdo la distribución de la población en la generación 80, Del lado derecho la distribución de la población en la Generación 120




Fig. 12. Del lado izquierdo la distribución de la población en la generación 160, Del lado derecho la distribución de la población en la Generación 200

2. De acuerdo a los resultados presentados encontramos que la estrategia de Deterministic Crowding logra de manera exitosa preservar las especies y con esto cumple con el objetivo de ofrecernos soluciones en varios optimos locales.

Trabajo Futuro.

Se recomienda para proseguir con el estudio de este problema, implementar politicas de restricción que son presentadas en la estrategia que se conoce como Deterministic Crowding Extendido.

References

1. Jonatan Gomez, *Self adaptation of operator rates for multimodal optimization*, Evolutionary Computation, 2004. CEC2004. Congress on, vol. 2, IEEE, 2004, pp. 1720–1726.
2. ———, *Self adaptation of operator rates in evolutionary algorithms*, Genetic and Evolutionary Computation—GECCO 2004, Springer, 2004, pp. 1162–1173.
3. Samir W Mahfoud, *A comparison of parallel and sequential niching methods*, Conference on genetic algorithms, vol. 136, Citeseer, 1995, p. 143.
4. Brad L Miller and Michael J Shaw, *Genetic algorithms with dynamic niche sharing for multimodal function optimization*, Evolutionary Computation, 1996., Proceedings of IEEE International Conference on, IEEE, 1996, pp. 786–791.